

# Análisis de Datos I

## Unidad 7: Regresión Lineal Simple

Clase: Regresión Lineal Simple

II Semestre de 2024



# Probabilidad y estadística para ingeniería y ciencias

NOVENA EDICIÓN

Walpole • Myers • Myers

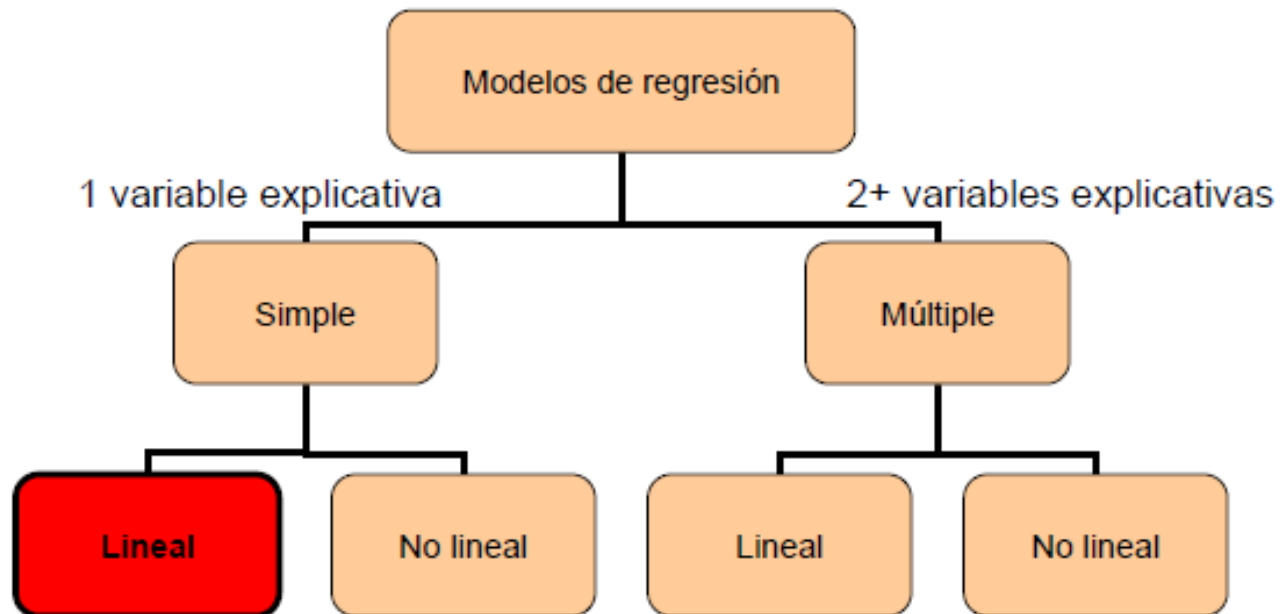
ALWAYS LEARNING

PEARSON

<b>11</b>	<b>Regresión lineal simple y correlación.....</b>	<b>389</b>
11.1	Introducción a la regresión lineal.....	389
11.2	El modelo de regresión lineal simple (RLS).....	390
11.3	Mínimos cuadrados y el modelo ajustado .....	394
	Ejercicios.....	398
11.4	Propiedades de los estimadores de mínimos cuadrados .....	400
11.5	Inferencias sobre los coeficientes de regresión.....	403
11.6	Predicción .....	408
	Ejercicios.....	411
11.7	Selección de un modelo de regresión .....	414
11.8	El método del análisis de varianza.....	414
11.9	Prueba para la linealidad de la regresión: datos con observaciones repetidas.....	416
	Ejercicios.....	421
11.10	Gráficas de datos y transformaciones .....	424
11.11	Estudio de caso de regresión lineal simple .....	428
11.12	Correlación .....	430
	Ejercicios.....	435
	Ejercicios de repaso .....	436
11.13	Posibles riesgos y errores conceptuales; relación con el material de otros capítulos .....	442

# Modelos de regresión

El análisis de regresión es un estudio de las relaciones entre variables: una variable dependiente y una o más variables independientes.



# Modelos de regresión

- Los problemas que involucran conjuntos de variables cuando se sabe que existe alguna relación inherente entre las variables se pueden resolver mediante modelos de regresión.
- Los modelos de regresión pueden ser lineales o no lineales dependiendo de la estructura de la ecuación y la relación entre las variables dependientes e independientes.

Lineales: Los parámetros están expresados en su menor exponente. Existen modelos lineales simples y múltiples.

Ejemplos de no lineales:

Exponencial	$\hat{y} = \beta_0 e^{\beta_1 x}$	Recíproca	$\hat{y} = \beta_0 + \beta_1 \frac{1}{x}$
Potencial	$\hat{y} = \beta_0 x^{\beta_1}$	Hiperbólica	$\hat{y} = \frac{x}{\beta_0 + \beta_1 x}$

# Modelo de regresión lineal simple

El modelo básico de regresión lineal simple (RLS) es:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Donde:


$\beta_0$  es el intercepto. Valor de  $Y$  cuando  $X=0$ .

$\beta_1$  es la pendiente. Cambio en  $Y$  por unidad de cambio en  $X$ .

$Y$  es la variable dependiente, variable de respuesta. No se puede controlar, es aleatoria.

$X$  es la variable independiente, regresor del modelo. Se puede controlar, no es aleatoria.

$\varepsilon$  es la perturbación, todo elemento que afecta a  $Y$ . Es aleatoria.  $E[\varepsilon]=0$




# Modelo de regresión lineal simple

Debemos encontrar los valores  $b_0$  y  $b_1$ , que corresponde a las estimaciones de  $\beta_0$  y  $\beta_1$  respectivamente, basándonos en una muestra de tamaño  $n$ , construyendo un conjunto de parejas  $(x_i, y_i)$ , de tal manera que la suma de los cuadrados de los residuos sea mínimo. A esta suma de cuadrados de los residuos se le llama suma de cuadrados de los errores (SSE, por sus siglas en inglés).

$$\hat{y} = b_0 + b_1x$$

$$SSE = \sum_{i=1}^n e_i^2$$



# Modelo de regresión lineal simple

La ecuación de regresión estimada será representada así:  $\hat{y} = b_0 + b_1x$

Modelo de Parámetro	Estimación
$\beta_0$	$b_0$
$\beta_1$	$b_1$
$\sigma^2$	$s_e^2$
$E(y x)$	$\hat{y}$

Los errores  $e=y - \hat{y}$  se denominan frecuentemente **residuales**.

# Procedimiento para realizar una R.L.S.

1. Identificar cuál es la variable dependiente ( $Y$ ) e independiente ( $X$ ).
2. Estimar  $\beta_0$  y  $\beta_1$  a partir de  $b_0$  y  $b_1$  (recta ajustada preliminar  $\hat{y} = b_0 + b_1 \cdot x$ ).
3. Determinar si  $\beta_0$  y  $\beta_1$  son significativos ( $\beta_0 \neq 0$  y  $\beta_1 \neq 0$ ).
  - 3.1. Realizar pruebas de hipótesis para  $\beta_0$  y  $\beta_1$  utilizando Dist. T Student.
  - 3.2. Realizar un ANOVA (prueba de hipótesis para  $\beta_1$  utilizando Dist. Fisher)
  - 3.3. Estimar intervalos de confianza para  $\beta_0$  y  $\beta_1$ .
4. Escribir la recta ajustada definitiva para  $\hat{y} = b_0 + b_1 \cdot x$ .
  - 4.1. Si  $\beta_1 = 0$  no hay relación entre  $X$  y  $Y$  (no hay recta).
  - 4.2. Si  $\beta_0 = 0$  y  $\beta_1 \neq 0$  la recta no tiene intercepto ( $\hat{y} = b_1 \cdot x$ ).
  - 4.3. Si  $\beta_0 \neq 0$  y  $\beta_1 \neq 0$  la recta sería igual a la preliminar ( $\hat{y} = b_0 + b_1 \cdot x$ ).



# Procedimiento para realizar una R.L.S.


5. Verificar qué tan buena es la recta ajustada (análisis de correlación).
  - 5.1. Coeficiente de determinación ( $R^2$ ).
  - 5.2. Coeficiente de correlación ( $\rho, \gamma$ ).
6. Verificar los supuestos realizados sobre los errores (análisis residual). Si los **tres supuestos** se cumplen, entonces la recta ajustada es válida.
  - 6.1. Verificar si los errores distribuyen normal con  $\mu = 0$  y  $\sigma^2 = s_e^2$  (realizar una prueba de bondad de ajuste).
  - 6.2. Verificar si los errores son independientes (Durbin-Watson).
  - 6.3. Verificar si los errores tienen una varianza constante (Homocedasticidad). Se realiza una gráfica de errores contra las variables  $X$  y/o  $Y$ .
7. Inferencias para la variable dependiente ( $Y$ ). Intervalos de confianza y predicción.

# Supuestos para el modelo de R.L.S.

- Para cada valor de  $x$ , la variable aleatoria  $\varepsilon$  se distribuye normalmente.
- Para cada valor de  $x$ , la media o valor esperado de  $\varepsilon$  es 0; esto es  $E(\varepsilon) = \mu_\varepsilon = 0$
- Para cada valor de  $x$ , la varianza de  $\varepsilon$  es la constante  $\delta^2$
- Los valores del término de error  $\varepsilon$  son independientes.

# Paso 1. Identificar las variables

El diagrama de dispersión se usa comúnmente para mostrar cómo dos variables se relacionan entre sí.



## Paso 2. Estimar $\beta_0$ y $\beta_1$ a partir de $b_0$ y $b_1$

### **Método de los mínimos cuadrados:**

Suma de cuadrados para la variable independiente  $SS_x = \sum x^2 - \frac{(\sum x)^2}{n}$

Suma de cuadrados para la variable dependiente  $SS_y = \sum y^2 - \frac{(\sum y)^2}{n}$

Suma de los productos cruzados  $SS_{xy} = \sum xy - \frac{(\sum x)(\sum y)}{n}$

Pendiente de la recta de regresión  $b_1 = \frac{SS_{xy}}{SS_x}$

Intercepto  $b_0 = \bar{y} - b_1 \bar{x}$

# Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

## 3.1. Realizar un ANOVA (prueba de hipótesis para $\beta_1$ utilizando D. Fisher)

El análisis de varianza divide la variación de  $Y$  en dos componentes: modelo de regresión y errores. La idea es que la variable dependiente  $Y$  sea explicada por  $\beta_0 + \beta_1 X$ , y que el error  $\varepsilon$  tenga una pequeña influencia en la variación.

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\begin{array}{l} \text{Suma de Cuadrados} \\ \text{Totales (SST)} \end{array} = \begin{array}{l} \text{Suma de} \\ \text{Cuadrados de la} \\ \text{Regresión (SSR)} \end{array} + \begin{array}{l} \text{Suma de} \\ \text{Cuadrados de} \\ \text{los Errores (SSE)} \end{array}$$

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

## Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

3.1. Realizar un ANOVA (prueba de hipótesis para  $\beta_1$  utilizando D. Fisher)

$SST = SS_y$	$SS_y = \sum y^2 - \frac{(\sum y)^2}{n}$
$SSR = b_1 \cdot SS_{xy}$	$SS_{xy} = \sum xy - \frac{(\sum x)(\sum y)}{n}$
$SSE = SS_y - b_1 \cdot SS_{xy}$	$SS_x = \sum x^2 - \frac{(\sum x)^2}{n}$

$SST$ : variabilidad total de  $Y$ .

$SSR$ : variabilidad de  $Y$  explicada por el modelo ajustado.

$SSE$ : variabilidad de  $Y$  explicada por los errores.

# Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

## 3.1. Realizar un ANOVA (prueba de hipótesis para $\beta_1$ utilizando D. Fisher)

Planteamiento de las hipótesis  $H_0: \beta_1 = 0$  y  $H_1: \beta_1 \neq 0$

Fuente de varianza	Suma de cuadrados	Grados de libertad	Cuadrados medios	$f_{\text{calculado}}$
Regresión	$SSR$	$1$	$MS_R = \frac{SSR}{1}$	$f_0 = \frac{SSR/1}{SSE/(n-2)} = \frac{SSR}{s_e^2}$
Error	$SSE$	$n-2$	$MS_E = s_e^2 = \frac{SSE}{n-2}$	
Total	$SST$	$n-1$		

Se rechaza  $H_0$  si  $f_0 > f_{1,n-2,\alpha}$  o si  $Valor\ P < \alpha$ ,  $Valor\ P = P(F_{1,n-2} > f_0)$

Si la hipótesis nula no es rechazada, el modelo no es válido para predecir Y. En el caso que la hipótesis nula sea rechazada, el modelo explica la variabilidad de Y, por lo tanto, es un modelo apropiado. Es deseable un F calculado grande para que la hipótesis nula sea rechazada en favor de la alternativa, lo que indica que  $\beta_1 \neq 0$

# Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

3.2. Realizar pruebas de hipótesis para  $\beta_0$  y  $\beta_1$  utilizando D. T de Student.

Pruebas de hipótesis para  $\beta_0$ :

$$H_0 : \beta_0 = B_0$$

$$H_0 : \beta_0 \leq B_0$$

$$H_0 : \beta_0 \geq B_0$$

$$H_1 : \beta_0 \neq B_0$$

$$H_1 : \beta_0 > B_0$$

$$H_1 : \beta_0 < B_0$$

Valor de la estadística de prueba:

$$t_0 = \frac{b_0 - B_0}{\sqrt{s_e^2 \cdot \left( \frac{1}{n} + \frac{\bar{x}^2}{SS_x} \right)}}$$

Distribución  $t$  con  $n - 2$  grados de libertad.

Planteamiento de las hipótesis  $H_0: \beta_0 = 0$  y  $H_1: \beta_0 \neq 0$



# Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

3.2. Realizar pruebas de hipótesis para  $\beta_0$  y  $\beta_1$  utilizando D. T de Student.

Pruebas de hipótesis para  $\beta_1$ :

$$H_0 : \beta_1 = B_1$$

$$H_0 : \beta_1 \leq B_1$$

$$H_0 : \beta_1 \geq B_1$$

$$H_1 : \beta_1 \neq B_1$$

$$H_1 : \beta_1 > B_1$$

$$H_1 : \beta_1 < B_1$$

Valor de la estadística de prueba:

$$t_0 = \frac{b_1 - B_1}{\sqrt{\frac{s_e^2}{SS_x}}}$$

Distribución  $t$  con  $n - 2$  grados de libertad.

Planteamiento de las hipótesis  $H_0: \beta_1 = 0$  y  $H_1: \beta_1 \neq 0$

## Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

### 3.3. Estimar intervalos de confianza para $\beta_0$ y $\beta_1$ .

Intervalos del  $(1 - \alpha)100\%$  de confianza para  $\beta_0$ :

$$b_0 - t_{n-2, \alpha/2} \cdot s_e \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{SS_x}} \leq \beta_0 \leq b_0 + t_{n-2, \alpha/2} \cdot s_e \sqrt{\frac{1}{n} + \frac{\bar{x}^2}{SS_x}}$$

Intervalos del  $(1 - \alpha)100\%$  de confianza para  $\beta_1$ :

$$b_1 - t_{n-2, \alpha/2} \cdot \frac{s_e}{\sqrt{SS_x}} \leq \beta_1 \leq b_1 + t_{n-2, \alpha/2} \cdot \frac{s_e}{\sqrt{SS_x}}$$

# Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

Caso Especial:  $\beta_0 = 0$  ( $\beta_0$  no es significativo).

ANOVA presenta modificaciones

Planteamiento de las hipótesis  $H_0: \beta_1 = 0$  y  $H_1: \beta_1 \neq 0$

Fuente de varianza	Suma de cuadrados	Grados de libertad	Cuadrados medios	$f_{calculado}$
Regresión	$SSR$	1	$MS_R = \frac{SSR}{1}$	$f_0 = \frac{SSR/1}{SSE/(n-1)} = \frac{SSR}{s_e^2}$
Error	$SSE$	$n-1$	$MS_E = s_e^2 = \frac{SSE}{n-1}$	
Total	$SST$	$n$		

Se rechaza  $H_0$  si  $f_0 > f_{1,n-1,\alpha}$  o si  $Valor P < \alpha$ ,  $Valor P = P(F_{1,n-1} > f_0)$

## Paso 3. Determinar si $\beta_0$ y $\beta_1$ son significativos

Caso Especial:  $\beta_0 = 0$  ( $\beta_0$  no es significativo).


Intervalo de confianza para  $\beta_1$  presenta modificaciones

Intervalos del  $(1 - \alpha)100\%$  de confianza para  $\beta_1$ :


$$b_1 - t_{n-1, \alpha/2} \cdot \frac{s_e}{\sqrt{SS_x}} \leq \beta_1 \leq b_1 + t_{n-1, \alpha/2} \cdot \frac{s_e}{\sqrt{SS_x}}$$

## Paso 4. Escribir la recta ajustada definitiva


4.1. Si  $\beta_1 = 0$  no hay relación entre  $X$  y  $Y$  (no hay recta).




4.2. Si  $\beta_0 = 0$  y  $\beta_1 \neq 0$  la recta no tiene intercepto ( $\hat{y} = b_1 \cdot x$ ).



4.3. Si  $\beta_0 \neq 0$  y  $\beta_1 \neq 0$  la recta sería igual a la preliminar ( $\hat{y} = b_0 + b_1 \cdot x$ ).




## Paso 5. Verificar qué tan buena es la recta




Para valores de X por encima de la media tenemos valores de Y por encima y por debajo en proporciones similares.

**Incorrelación.**

## Paso 5. Verificar qué tan buena es la recta



- Para los valores de X mayores que la media le corresponden valores de Y mayores también.
- Para los valores de X menores que la media le corresponden valores de Y menores también.
- Esto se llama **relación directa** o creciente entre X e Y.



Para los valores de X mayores que la media le corresponden valores de Y menores. Esto es **relación inversa** o decreciente.


# Paso 5. Verificar qué tan buena es la recta

## 5.1. Coeficiente de correlación

El coeficiente de correlación de Pearson mide el grado de asociación lineal entre  $X$  y  $Y$ . Se puede estimar por medio del coeficiente de correlación muestral o estimado.

$$\rho = \frac{Cov(X, Y)}{\sigma_X \sigma_Y} = \beta_1 \frac{\sigma_X}{\sigma_Y} \quad -1 \leq \rho \leq 1$$

$$\gamma = b_1 \sqrt{\frac{S_{xx}}{S_{yy}}} \quad -1 \leq \gamma \leq 1$$





# Paso 5. Verificar qué tan buena es la recta

## 5.1. Coeficiente de correlación

- $\rho = 0$  cuando  $\beta = 0$ : No existe regresión lineal, es decir, la recta de regresión es horizontal y cualquier conocimiento de  $X$  es inútil para predecir  $Y$ .
- $\rho = \pm 1$  cuando  $\sigma^2 = 0$  : Existe relación lineal perfecta entre las dos variables
- Los estimadores muestrales de  $\rho$  con valores cercanos a la unidad implican una buena correlación entre  $X$  y  $Y$ .
- Los estimadores muestrales de  $\rho$  con valores cercanos a cero implican poca o ninguna correlación entre  $X$  y  $Y$ .

# Paso 5. Verificar qué tan buena es la recta

## 5.2. Coeficiente de determinación

El coeficiente de determinación, denotado  $R^2$  es la proporción de la varianza en la variable dependiente que es predecible a partir de la(s) variable(s) independiente(s)

$$R^2 = 1 - \frac{SSE}{SST} = \frac{SSR}{SST}$$

0.9 – 1.0	Excelente
0.8 – 0.9	Muy bueno
0.6 – 0.8	Bueno
0.5 – 0.6	Regular
< 0.5	Malo

$SST$ : variabilidad total de  $Y$ .

$SSR$ : variabilidad de  $Y$  explicada por el modelo ajustado.

$SSE$ : variabilidad de  $Y$  explicada por los errores.

Determina la calidad del modelo para replicar los resultados, y a su vez representa la proporción de variación de los resultados que puede explicarse por el modelo.

# Paso 6. Verificar supuestos sobre los errores

6.1. Verificar si los errores distribuyen normal con  $\mu = 0$  y  $\sigma^2 = s_e^2$

$H_o$  : Los residuos se distribuyen normalmente con media  $\mu = 0$  y varianza  $\sigma^2$  estimada con  $s_e^2$

$H_1$  : Los residuos **NO** se distribuyen normalmente con media  $\mu = 0$  y varianza  $\sigma^2$  estimada con  $s_e^2$

Se determinan los residuos  $e_i = y_i - \hat{y}_i$  para las observaciones en la muestra y se aplica la prueba de bondad de ajuste chi-cuadrado.

# Paso 6. Verificar supuestos sobre los errores

## 6.2. Verificar si los errores son independientes

La independencia de los residuos se puede probar mediante el análisis de gráfico de residuos, que en el caso que exista un patrón, se rechaza  $H_0$ . Otra forma de probarlo es utilizando la prueba Durbin-Watson, que es la más empleada para detectar auto correlación en los errores.

$H_0$ : Los residuos son independientes.

$H_1$ : Los residuos son dependientes.

El estadístico Durbin-Watson tomará valores entre 0 y 4, y si este valor es cercano a 2 los residuos se asumen independientes. Para cierto nivel de significancia se buscan los valores  $d_l$  y  $d_u$  de la tabla de Durbin-Watson.

Si  $0 \leq D_w \leq d_l$ , correlación negativa

Si  $d_l \leq D_w \leq d_u$ , inconcluso

Si  $d_u \leq D_w \leq 4 - d_u$ , los residuos son independientes

Si  $4 - d_u \leq D_w \leq 4 - d_l$ , inconcluso

Si  $4 - d_l \leq D_w \leq 4$ , correlación positiva

$$D_w = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}$$

# Paso 6. Verificar supuestos sobre los errores


## 6.3. Verificar si los errores tienen una varianza constante (Homocedasticidad)

La homocedasticidad indica la homogeneidad de la varianza.

$H_0$ : Los residuos son homocedásticos.

$H_1$ : Los residuos son heterocedásticos.

Se realiza una gráfica de errores  $e_i$  contra  $\hat{y}$  o contra  $x$ , o de  $e_z$  (residuos estandarizados) contra  $\hat{y}$  o contra  $x$ . Los residuos deben estar dispersos alrededor del cero de forma aleatoria, entre -3 y 3 desviaciones estándar de la media sin mostrar ningún patrón



# Paso 6. Verificar supuestos sobre los errores

## 6.3. Verificar si los errores tienen una varianza constante (Homocedasticidad)

La **prueba de Breusch-Pagan** se utiliza para determinar si la heteroscedasticidad está presente o no en un modelo de regresión.

La prueba utiliza las siguientes hipótesis nulas y alternativas :

**Hipótesis nula ( $H_0$ ):** la homocedasticidad está presente (los residuos se distribuyen con la misma varianza).

**Hipótesis alternativa ( $H_1$ ):** Heteroscedasticidad está presente (los residuos no se distribuyen con la misma varianza).

Si el valor p que corresponde a este estadístico de prueba de chi-cuadrado con p (el número de predictores) grados de libertad es menor que algún nivel de significancia ( $\alpha$ ), entonces rechaza la hipótesis nula y concluya que la heteroscedasticidad está presente. De lo contrario, no rechaza la hipótesis nula. En este caso, se asume que existe homocedasticidad.

# Paso 6. Verificar supuestos sobre los errores

## 6.3. Verificar si los errores tienen una varianza constante (Homocedasticidad)

Usamos los siguientes pasos para realizar una prueba de Breusch-Pagan:

1. Ajuste el modelo de regresión.
2. Calcule los residuos cuadrados del modelo.
3. Ajuste un nuevo modelo de regresión, utilizando los residuos al cuadrado como valores de respuesta.
4. Calcule el estadístico de prueba de chi-cuadrado  $X^2$  como  $n * R^2_{\text{nuevo}}$  nuevo donde:
  - $n$ : el número total de observaciones
  - $R^2_{\text{nuevo}}$  : R-cuadrado del nuevo modelo de regresión que utilizó los residuos al cuadrado como valores de respuesta.

# Paso 6. Verificar supuestos sobre los errores

## 6.3. Verificar si los errores tienen una varianza constante (Homocedasticidad)

- Si la gráfica de residuos contra valores ajustados ( $\hat{y}$ ) no muestra una tendencia importante, es *homocedástica*, es probable pero no se tiene la seguridad que los supuestos del modelo lineal sean válidos. Sin embargo si la gráfica de residuos muestra tendencia importante o se curva, es *heterocedástica*. Si esto ocurre se realiza una transformación de la variable de interés, elegir la transformación adecuada es difícil y no siempre funcionan, si este es el caso se debe pensar en una regresión múltiple.
- Examinar datos atípicos o puntos influyentes.
- El coeficiente de correlación es una medida numérica de la fuerza de la relación lineal entre de las variables, no indica cualquier otro tipo de relación.



# Paso 7. Inferencias para $Y$

Intervalos de confianza y predicción para la variable dependiente

Intervalos de  $(1 - \alpha)100\%$  de confianza para la respuesta media  $E(y|x_0)$ :

$$\hat{y} - t_{n-2, \alpha/2} \cdot s_e \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SS_x}} \leq E(y|x_0) \leq \hat{y} + t_{n-2, \alpha/2} \cdot s_e \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SS_x}}$$

Intervalos de predicción del  $(1 - \alpha)100\%$  de confianza para  $y$  dado  $x = x_0$ :

$$\hat{y} - t_{n-2, \alpha/2} \cdot s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SS_x}} \leq y|x_0 \leq \hat{y} + t_{n-2, \alpha/2} \cdot s_e \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{SS_x}}$$